VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ
FAKULTA INFORMAČNÍCH TECHNOLOGIÍ

IFJ - Projektová dokumentace

Implementace překladače jazyka IFJ22

Tým "Tým xkalis03", varianta BVS

Autoři:

(v)	Vojtěch Kališ (xkalis03)	25%
	Jan Lutonský (xluton02)	25%
	Jan Salaš (xsalas02)	25%
	Lucie Hlaváčová (xhlava60)	25%

Implementovaná rozšíření: FUNEXP

Obsah

1 Úvod

Cílem tohoto projektu bylo vytvořit překladač implementovaný v jazyce C, který ze standartního vstupu načte vstupní kód napsaný v jazyce IFJ22, přeloží jej do cílového jazyka IFJcode22 a výskedek pak vypíše na standartní výstup. Jazyk IFJ22 vznikl jako obdoba jazyka PHP.

2 Implementace

Celý překladač jsme si rozdělili na více dílčích problémů, jejichž funkčnost byla individuálně testována. Tyhle dílčí problémy byly nadále vzájemně propojovány a opět testována jejich funkčnost.

2.1 Lexikální analyzátor

Lexikální analyzátor jsme implementovali jako deterministický konečný automat. Z důvodu přehlednosti jsme se rozhododli jednotlivé stavy implementovat jako funkce, namísto vnořených $switch$ příkazů. Lexikální analyzátor pracuje ve třech módech:

- START
  V tomto stavu se analyzátor snaží načítat token prologu $<?php$. Po načtení se přesune do stavu CONTINUE. Pokud v tomto módu nalezne cokoliv jiného, jedná se o lexikální chybu.
- CONTINUE
  V tomto stavu se analyzátor snaží zjistit, zda se po prologu nachází speciální token $declare(strict\_types = 1);$. Pokud ano, zpracuje jej jako validní token, jinak se přesouvá do stavu NORMAL.
- NORMAL
  V tomto stavu se analyzátor snaží načítat všechny ostatní tokeny. V případě, že se aktuální vstup neshoduje s žádným z definovaných tokenů, jedná se o lexikální chybu.

Na začátku programu se lexikální analyzátor inicializuje funkcí lex_init. Ta rovnou načte první token ze vstupu a vrátí jej syntaktickému analyzátoru. Pro získání dalšího tokenu syntaktický analyzátor zavolá funkci lex_next.

2.2 Syntaktický analyzátor

Syntaktický analyzátor je závislý na lexikalním; volá jeho funkce aby získal nový token. Tokeny jsou předávány přes strukturu context, která slouží pro sdílení dat mezi částmi překladače. Pro implementaci syntaktické analýzy byla zvolena metoda rekurzivního sestupu. Při návrhu gramatiky jsme narazili na problém, kdy pravidlo pro příkaz přiřazení výrazu do proměné kolidovalo s výrazem bez přizazení, který osahuje pouze identifikátor, a z tohoto důvodu jsme se rozhodli přemístit syntaktickou analýzu příkazu přiřazení do precedenční syntaktické analýzy. Další problém pak byl ještě nalezen při volání funkcí, kde, z důvodu našeho rozhodnutí implementovat rozšíření FUNEXP, bylo potřeba zajistit možnost analyzovat funkce i uprostřed výrazů a jelikož nám přišlo složité přepínat mezi syntaktickou analýzou rekurzivním sestupem a syntaktickou analýzou precedenční tabulkou, tak jsme se rozhodli přemístit volání funkce jen do syntaktické analýzi precedenční tabulkou. Analyzátor při své funkci tvoří abstraktní syntaktický strom, který je dále zpracováván dalšími částmi překladače.

2.2.1 Precedenční syntaktický analyzátor

Slouží ke zpracování výrazů, přikazu přiřazení do proměné a volání funkce. Při tvorbě precedenční tabulky bylo zpozorováno, že operátory je možné sjednotit do množin se stejnou precedencí, díky čemuž bylo možné

tabulku zmenšit. Precedenční analyzátor analyzuje vstupní tokeny získané z lexikálního analyzátoru přes strukturu context, dokud nenarazí na první token, který se nesmí vyskytovat ve výrazu, volání funkce nebo v příkazu přiřazení. Tento token není zkonzumován a je ponechán v struktuře context pro další zpracování syntaktickým analyzátorem metodou rekurzivního sestupu. Redukce gramatických pravidel na zásobníku precedenční syntaktycké analýzy probíhají pomocí stavového automatu posaném diagramem na konci dokumentu.

2.3 Sémantický analyzátor

Sémantický analyzátor provádí sémantickou analýzu nad vstupním programem, a je obsažen v souboru *semantic.c*; jeho hlavičkový soubor pak analogicky nese název *semantic.h*. Sémantický analyzátor pracuje převážně s *globální tabulkou symbolů* (využívající implementace tabulky symbolů a abstraktním syntaktickým stromem (dále jen ASS); obojí se nachází ve sdílené struktuře Context. Očekává se korektní naplnění ASS v rámci syntaktické analýzy. Na začátku své funkce sémantický analyzátor projde ASS a vyhledá v něm všechny definice funkcí, jež vloží jakožto nody s typem *function* do globální tabulky symbolů; možné parametry definované při deklaraci funkce zase vloží do *lokální tabulky symbolů* dané funkce jakožto nody s typem *variable*. Do globální tabulky symbolů jsou také vloženy deklarace vestavěných funkcí (zavoláním funkce), společně s funkcí nazvanou ":b"sloužící jako hlavní tělo programu (*body*).

Jakmile je vše připraveno, Sémantický analyzátor vstoupí do funkce *AST_DF_traversal*, plnící funkci hlavní smyčky, která prochází již zmíněný AST do hloubky a v rámci switch case-u pak hledá AST nody, jejichž sémantickou korektnost je třeba prověřit; jakmile nějakou takovou nodu najde, spustí nad ní speciální funkci zabývající se prověřením sémantické korektnosti toho konkrétního typu AST nody. V případě, že je nalezena sémantická chyba, program ukončí svou činnost, vypropaguje kód odpovídající nalezené chybě, a zaručí, že dojde ke kompletnímu uvolnění veškeré alokované paměti.

2.4 Generátor cílového kódu

Na začátku programu jsou definovány globální proměné a lokální proměné na hodnotu nill. Dále následuje hlavní telo programu. Na konci jsou vygenerovány všechny vestavěné funkce.

2.4.1 Definice funkcí

Při vstupu do funkce se vytvoří nový lokální rámec, do něž se přesunou parametry volané funkce z datového zásobníku, a následně jsou inicializovány všechny lokální proměné v lokálním rámci na nil. Na konci funkce se na datový zásobník vloží návratová hodnota funkce a to i v případě funkcí vracejících void, v tomto případě se vrací nil.

2.4.2 Volání funkcí

Při volání funkce se na datový zásobní vloží všechny parametry volané funkce zprava do leva, a pokud se jedná o vestavěnou funkci write (jediná variadická funkce) je nakonec na datový zásobník vložen i počet předaných parametrů funkce. Při návratu z funkce je návratová hodnota ponechána na datovém zásobníku pro další zpracování.

2.4.3 Výrazy

Výrazy jsou vyhodnovocány převážne za použití datového zásobníku. Při generování výrazů jsou prováděny dynamické typové konverze podle tabulky ze zadání.

3 Speciální datové struktury

3.1 Context

Jedná se o strukturu určenou pro sdílení dat mezi lexikálním analyzátorem, syntaktickým analyzátorem, sémantickým analyzátorem i generátorem cílového kódu. Obsahuje globální tabulku symbolů, buffed posledního tokenu, buffer atributu posledního tokenu (jeho přímá "stringová reprezentace"), kořen AST a zásobník pro precedenční syntaktickou analýzu.

3.2 Abstraktní syntaktický strom

Je implementován jako N-ární strom. Tento strom je tvořen při syntaktické analýze a slouží jako vnitřní reprazentace vstupního kódu. Abstraktní syntaktický strom je ze syntaktické analýzy předávan analýze sémantické, která jej prochází a kontroluje sémantickou korektnost. Po ověření sémantickou analýzout je strom dále předán generátoru cílového kódu, který strom projde a generuje úseky kódu v závislosti na uzlech stromu. N-arní strom zjednodušil zpracování zřetězených gramatických pravidel, jako například seznam parametrů při definici funkce nebo seznam parametrů při volání funkce.

3.3 Generický zásobník

Je implementován pomocí dynamického pole ukazatelů na void. Při přidávání prvků na zásobník může dojít místo v dynamickém poli, v takovém případě je k poli přialokováno 24 volných slotů zásobníku pomocí funkce realloc. Přialokovávání 24 položek by mělo být dostatečné, avšak nebyly podniknuty žádná měření či testy které by tuhle skutečnost potrdily.

3.4 Zásobník pro precedenční syntaktickou analýzu

Je přetypovaná struktura generického zásobníku. Pro tento zásobník byly vytvořeny funkce, které správně přetypují vstupy a výstupy tak, aby bylo možné volat funkce generického zásobníku. Samotný zásobník slouží pro ukládání uzlů syntaktického stromu, které jsou následně redukovány precedenčním syntaktickým analyzátorem.

3.5 Tabulka symbolů

Tabulka symbolů byla implementována jako binární vyhledávací strom, což bylo i nárokem naší varianty zadání. Téměř celá tabulka symbolů je napsána nerekurzivním (tedy iterativním) postupem, a to především z důvodu snížení časové komplexity na úkor složitější implementace. Tabulka symbolů je využívána Sémantickým analyzátorem pro vytvoření Globální tabulky symbolů a její využití je již popsáno v rámci jeho popisu.

3.6 Obousměrně vázaný seznam

Implementaci obousměrně vázaného seznamu lze najít v souboru *dll.c*, a odpovídající hlavičkový soubor pak pod názvem *dll.h*. Obousměrně vázaný seznam je v projektu využíván ve struktuře nody Tabulky symbolů, a to pro účely snadného uchování názvů argumentů vkládaných funkcí.

4 Práce v týmu

Na projektu jsme začali pracovat ihned po zveřejnění zadání, a to jeho prostudováním a domluvením první schůzky, v rámci které byla vypracována prvotní verze pravidel LL-gramatiky, a LL tabulka. Obojí se ještě v čase dalších několika týdnů upravovalo v případě nalezení chyby, až se nakonec vše ustálilo do konečné podoby, prezentované v tomhle dokumentě a dohledatelné na jeho konci.

Dále jsme si jednotlivé části rozdělili mezi sebe a pracovali na nich jako jednotlivci popřípadě dvojice. Stále probíhaly schůzky, například pro řešení implementačních záležitostí a to především způsobu komunikace jednotlivých částí překladače, ovšem zvětšiny docházelo spíše k průběžnému testování překladače jako celku a kontrole pokroku ve vývoji.

4.1 Komunikace

Pro komunikaci byla využita aplikace *Discord*, kde byl vytvořen vlastní server na kterém pak probíhala veškerá vzájemná komunikace, ať už se jednalo o komunikaci textovou, hovorové schůzky celotýmové i třeba v menším počtu, nebo sdílení materiálů, diagramů apod.

4.2 Vzdálený repozitář

Jako vzdálený repozitář jsme zvolili Github, jenž nám umožnil sdílet mezi sebou zdrojové kódy dílčích úkolů a navzájem si testovat nejen funkčnost jednotlivých částí, ale i překladač jako celek.

4.3 Rozdělení práce v týmu

Vojtěch Kališ (xkalis03):	Sémantická analýza, Tabulka symbolů, Speciální datové struktury, Testování, Dokumentace
Jan Lutonský (xluton02):	Syntaktická analýza, Precedenční syntaktická analýza, Generátor cílového kódu, Speciální datové struktury, Testování, Dokumentace
Jan Salaš (xsalas02):	Lexikální analýza, Speciální datové struktury, Testování, Dokumentace
Lucie Hlaváčová (xhlava60):	Lexikální analýza, Speciální datové struktury, Testování, Dokumentace

5 Závěr

Ačkoliv byla práce na projektu započata poměrně brzy, díky jeho rozměrnosti nám i tak implementace překladače zabrala spoustu času a stála spoustu úsilí. Avšak zkušenosti, získané během řešení projektu, a to nejen z hlediska programovacího, nýbrž i komunikace v týmu a rozebírání logistických problémů, bere celý tým jako velice přínosné a nenahraditelné.

Během projektu jsme se potýkali s nesrovnalostmi v zadání či přímo chybějící specifikace některých specifik, avšak ty byly vyřešeny konzultací fóra k projektu. Velice nám také pomohlo pokusné odevzdání, které nám dodale důležitou zpětnou vazbu ještě před řádným termínem odevzdání.

DKA pro lexikální analyzátor

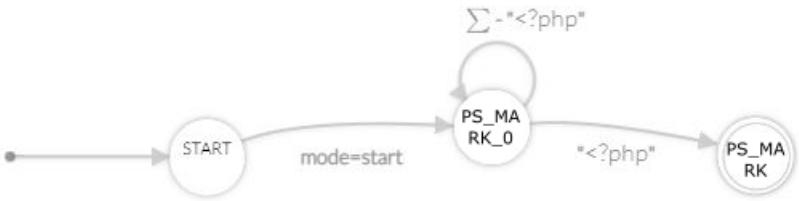

Obrázek 1: DKA pro START stav lexeru

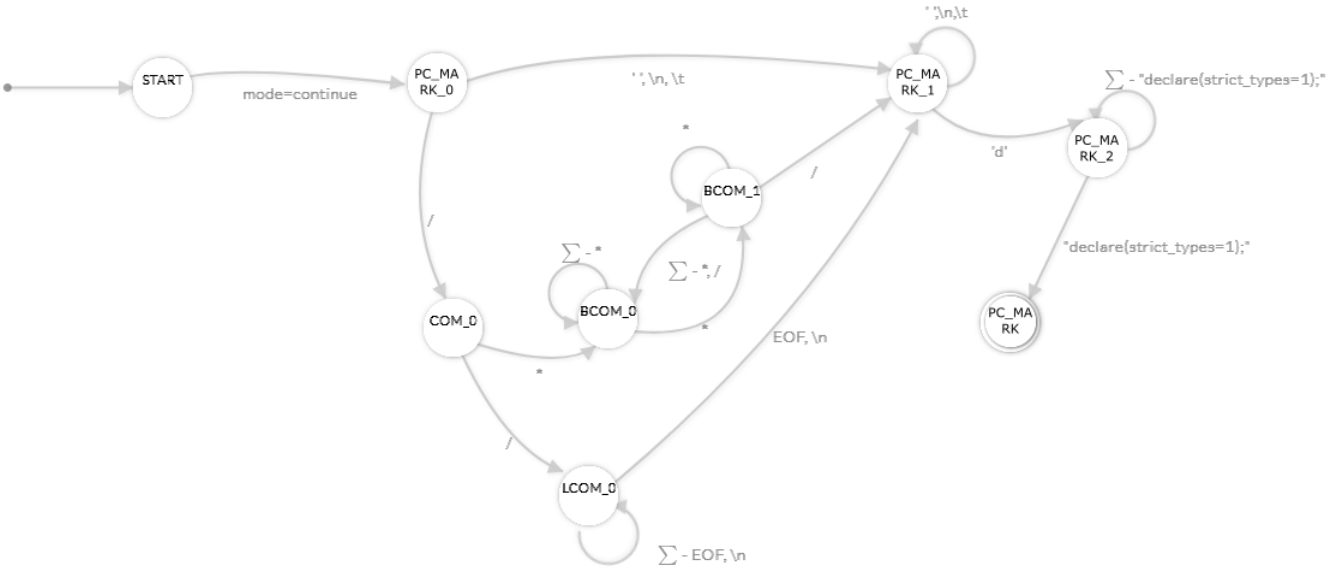

Obrázek 2: DKA pro CONTINUE stav lexeru

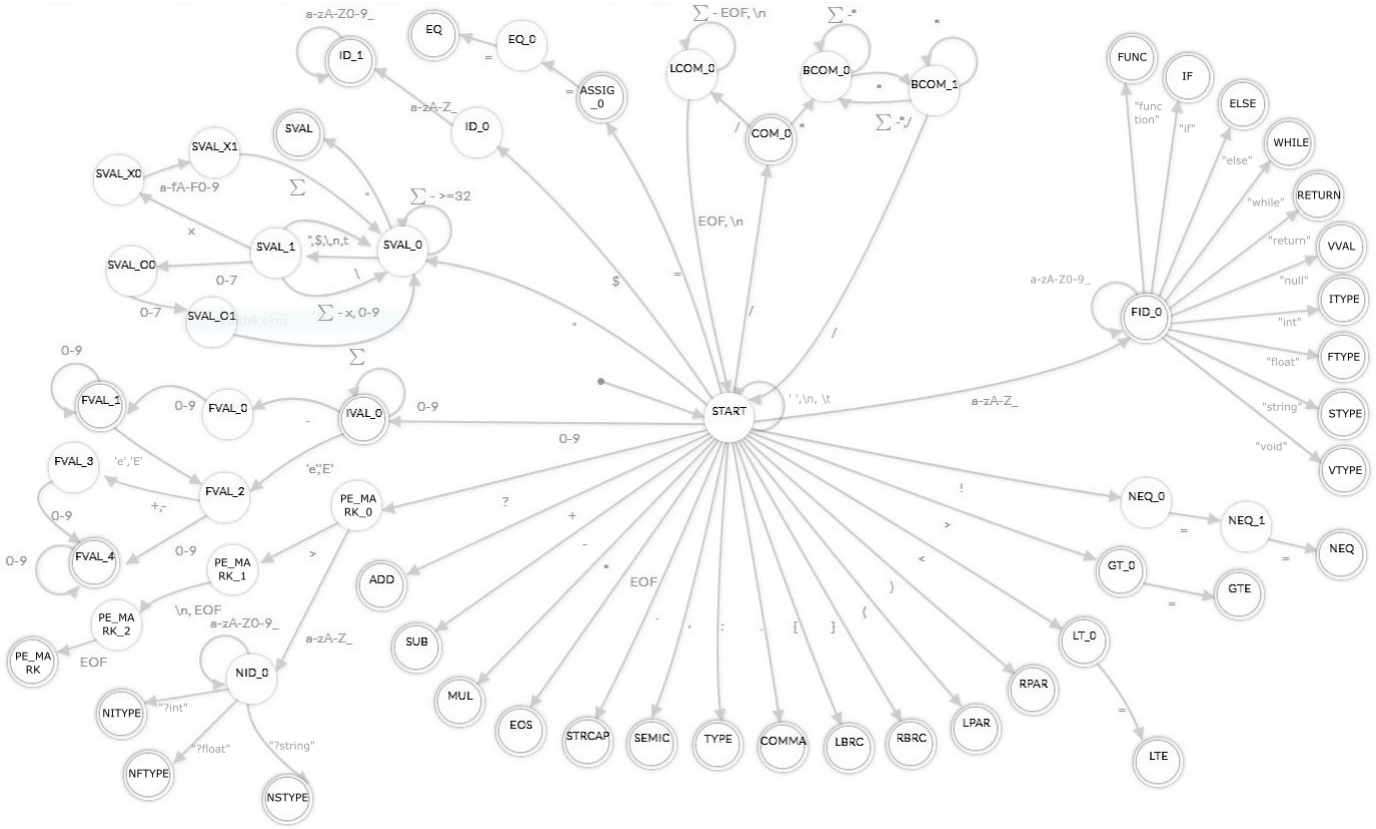

Obrázek 3: DKA pro NORMAL stav lexeru

*

*

Precedenční tabulka

```
FID  :  function = {FID}
ID   :  ID
TERM : term = {IVAL|FVAL|SVAL|NUL}
CL1  : class1 = {*| \ }
CL2  : class2 = {+| -|  .}
CL3  : class3 = {<| >| <=| >=}
CL4  : class4 = {===| !==}
```

	FID	ID	TERM	CL1	CL2	CL3	CL4	(	)	,	=	$
F	{ ERROR	ERROR	ERROR	ERROR	ERROR	ERROR	ERROR	<	ERROR	ERROR	ERROR	ERROR }
I	{ ERROR	ERROR	ERROR	>	>	>	>	ERROR	>	>	<	> }
T	{ ERROR	ERROR	ERROR	>	>	>	>	ERROR	>	>	ERROR	> }
CL1	{ <	<	<	>	>	>	>	<	>	>	ERROR	> }
CL2	{ <	<	<	<	>	>	>	<	>	>	ERROR	> }
CL3	{ <	<	<	<	<	>	>	<	>	>	ERROR	> }
CL4	{ <	<	<	<	<	<	>	<	>	>	ERROR	> }
(	{ <	<	<	<	<	<	<	<	=	<	ERROR	ERROR }
)	{ ERROR	ERROR	ERROR	ERROR	ERROR	ERROR	ERROR	ERROR	ERROR	>	ERROR	ERROR }
,	{ <	<	<	<	<	<	<	<	>	>	ERROR	ERROR }
=	{ <	<	<	<	<	<	<	<	>	>	ERROR	> }
$	{ <	<	<	<	<	<	<	<	ERROR	<	<	ACCEPT }

Obrázek 4: Precedenční tabulka

Pravidla LL gramatiky

```
prog -> PS_MARK PC_MARK prog_body

prog_body -> body_part prog_body
           | fun_def prog_body
           | EPS

prog_end -> PE_MARK EOS
          | EOS

body -> body_part body
      | EPS

body_part -> if_n
           | while_n
           | extended_expr
           | ret

extended_expr -> EXPR SEMIC
               | EXPR_FCALL SEMIC
               | EXPR_PAR SEMIC
               | EXPR_ASSIGN SEMIC

ret -> RETURN ret_cont
ret_cont -> EXPR SEMIC
          | EXPR_PAR SEMIC
          | EXPR_FCALL SEMIC
          | SEMIC

while_n -> WHILE EXPR_PAR LBRC body RBRC

if_n -> IF EXPR_PAR LBRC body RBRC else_n
else_n -> ELSE LBRC body RBRC
        | EPS

fun_def -> FUNC F_ID LPAR par_list RPAR TYPE ret_type LBRC fun_body RBRC

par_list -> type_n ID par_list_cont
          | EPS

par_list_cont -> COMMA par_list
               | EPS

ret_type -> type_n
          | VTYPE

type_n -> STYPE
        | ITYPE
        | FTYPE
        | NSTYPE
        | NITYPE
        | NFTYPE
```